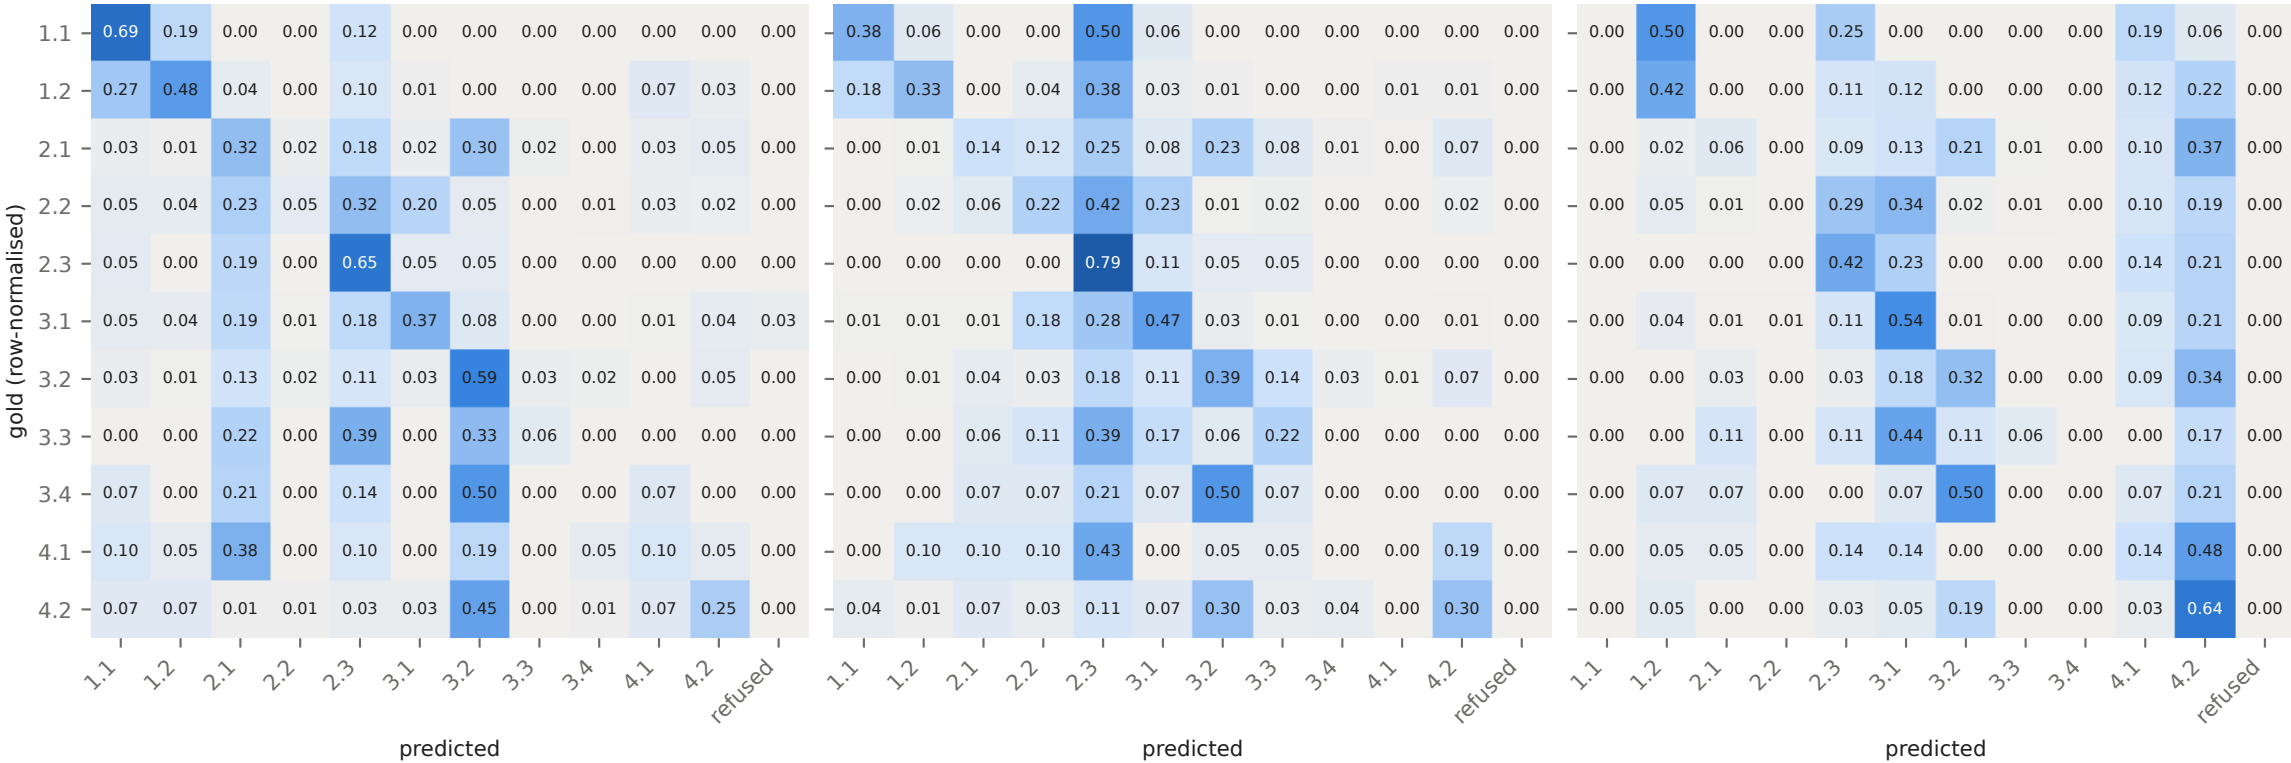
Gemma-4-E4B
Falcon-H1-7B
GLM-Edge-4B
gold (row-normalised)
1.1 0.69 0.19 0.00 0.00 0.12 0.00 0.00 0.00 0.00 0.00 0.00 0.00
1.2 0.27 0.48 0.04 0.00 0.10 0.01 0.00 0.00 0.00 0.07 0.03 0.00
2.1 0.03 0.01 0.32 0.02 0.18 0.02 0.30 0.02 0.00 0.03 0.05 0.00
2.2 0.05 0.04 0.23 0.05 0.32 0.20 0.05 0.00 0.01 0.03 0.02 0.00
2.3 0.05 0.00 0.19 0.00 0.65 0.05 0.05 0.00 0.00 0.00 0.00 0.00
3.1 0.05 0.04 0.19 0.01 0.18 0.37 0.08 0.00 0.00 0.01 0.04 0.03
3.2 0.03 0.01 0.13 0.02 0.11 0.03 0.59 0.03 0.02 0.00 0.05 0.00
3.3 0.00 0.00 0.22 0.00 0.39 0.00 0.33 0.06 0.00 0.00 0.00 0.00
3.4 0.07 0.00 0.21 0.00 0.14 0.00 0.50 0.00 0.00 0.07 0.00 0.00
4.1 0.10 0.05 0.38 0.00 0.10 0.00 0.19 0.00 0.05 0.10 0.05 0.00
4.2 0.07 0.07 0.01 0.01 0.03 0.03 0.45 0.00 0.01 0.07 0.25 0.00
1.1 0.38 0.06 0.00 0.00 0.50 0.06 0.00 0.00 0.00 0.00 0.00 0.00
1.2 0.18 0.33 0.00 0.04 0.38 0.03 0.01 0.00 0.00 0.01 0.01 0.00
2.1 0.00 0.01 0.14 0.12 0.25 0.08 0.23 0.08 0.01 0.00 0.07 0.00
2.2 0.00 0.02 0.06 0.22 0.42 0.23 0.01 0.02 0.00 0.00 0.02 0.00
2.3 0.00 0.00 0.00 0.00 0.79 0.11 0.05 0.05 0.00 0.00 0.00 0.00
3.1 0.01 0.01 0.01 0.18 0.28 0.47 0.03 0.01 0.00 0.00 0.01 0.00
3.2 0.00 0.01 0.04 0.03 0.18 0.11 0.39 0.14 0.03 0.01 0.07 0.00
3.3 0.00 0.00 0.06 0.11 0.39 0.17 0.06 0.22 0.00 0.00 0.00 0.00
3.4 0.00 0.00 0.07 0.07 0.21 0.07 0.50 0.07 0.00 0.00 0.00 0.00
4.1 0.00 0.10 0.10 0.10 0.43 0.00 0.05 0.05 0.00 0.00 0.19 0.00
4.2 0.04 0.01 0.07 0.03 0.11 0.07 0.30 0.03 0.04 0.00 0.30 0.00
1.1 0.00 0.50 0.00 0.00 0.25 0.00 0.00 0.00 0.00 0.19 0.06 0.00
1.2 0.00 0.42 0.00 0.00 0.11 0.12 0.00 0.00 0.00 0.12 0.22 0.00
2.1 0.00 0.02 0.06 0.00 0.09 0.13 0.21 0.01 0.00 0.10 0.37 0.00
2.2 0.00 0.05 0.01 0.00 0.29 0.34 0.02 0.01 0.00 0.10 0.19 0.00
2.3 0.00 0.00 0.00 0.00 0.42 0.23 0.00 0.00 0.00 0.14 0.21 0.00
3.1 0.00 0.04 0.01 0.01 0.11 0.54 0.01 0.00 0.00 0.09 0.21 0.00
3.2 0.00 0.00 0.03 0.00 0.03 0.18 0.32 0.00 0.00 0.09 0.34 0.00
3.3 0.00 0.00 0.11 0.00 0.11 0.44 0.11 0.06 0.00 0.00 0.17 0.00
3.4 0.00 0.07 0.07 0.00 0.00 0.07 0.50 0.00 0.00 0.07 0.21 0.00
4.1 0.00 0.05 0.05 0.00 0.14 0.14 0.00 0.00 0.00 0.14 0.48 0.00
4.2 0.00 0.05 0.00 0.00 0.03 0.05 0.19 0.00 0.00 0.03 0.64 0.00
1.1 1.2 2.1 2.2 2.3 3.1 3.2 3.3 3.4 4.1 4.2 refused
predicted
predicted
predicted